

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO
Lab 2: Parsing and Matching

SINH VIÊN THỰC HIỆN:

Mai Đình Trí – MSSV: 23120377

GIẢNG VIÊN HƯỚNG DẪN

Huỳnh Lâm Hải Đăng

Tp. Hồ Chí Minh, tháng 1/2026

1. Giới thiệu

Trong bài lab này, sinh viên được yêu cầu cụ thể 2 phần:

1. Cài đặt một bộ phân tích tự động để xử lý các tệp nguồn LaTeX đã thu thập từ bài lab1.
2. Thực hiện tác vụ khớp giữa các tham chiếu đã được trích xuất và chuẩn hóa ở trên thành file **refs.bib** với dữ liệu **references.json** đã thu thập. Mục tiêu là xác định mục BibTeX đã trích xuất nào tương ứng với arXiv ID nào trong tệp **references.json**.

2. Quy trình thực hiện

2.1 Phân tích phân cấp

2.1.1 Xử lý đa tập tin

Để xử lý cấu trúc dự án LaTeX phức tạp thường chia nhỏ thành nhiều file .tex, tôi áp dụng chiến lược "Recursive Flattening" (Làm phẳng đệ quy):

- Main File Detection: Hệ thống tự động quét thư mục để tìm file chính (main file) dựa trên sự hiện diện của lệnh `\documentclass`
- Recursive Merging: Sử dụng thuật toán đệ quy DFS để quét nội dung. Khi gặp các lệnh `\input{filename}` hoặc `\include{filename}`:
 - + Hệ thống tạm dừng đọc file hiện tại.
 - + Đọc nội dung của file con được tham chiếu.
 - + Thay thế dòng lệnh `\input` bằng toàn bộ nội dung của file con.
 - + Quá trình này lặp lại cho đến khi không còn file con nào, tạo ra một chuỗi văn bản LaTeX liền mạch duy nhất (`full_latex`) chứa toàn bộ nội dung bài báo.
- Cycle Prevention: Một cơ chế kiểm tra `visited_files` được tích hợp để phát hiện và ngăn chặn vòng lặp vô hạn nếu các file include lẫn nhau (Circular Dependency).

2.1.2 Phát hiện cấu trúc và Phân tích cây

Quy trình chuyển đổi từ văn bản phẳng sang cây phân cấp (Hierarchical Tree) được thực hiện qua 2 bước chính:

Bước 1: Regex Tokenization (Phân rã Token):

- Sử dụng Regular Expressions (Regex) để quét và xác định các khối cấu trúc quan trọng.
- Tôi định nghĩa một bản đồ cấp độ (`LEVEL_MAP`) để gán trọng số cho từng loại token:
 - + *Root*: Document (Level 0).
 - + *Containers*: Section (1), Subsection (2), ..., Paragraph (4), Itemize (5).
 - + *Leafs*: Item (6), Sentence/Equation/Figure (7).

- Văn bản được chia cắt thành một danh sách các tokens tuần tự, trong đó các đoạn văn bản thường nằm giữa các thẻ cấu trúc sẽ được tách thành các câu (sentences) bằng thư viện NLTK.

Bước 2: Stack-based Tree Construction (Dựng cây dựa trên Ngăn xếp):

- Tôi sử dụng cấu trúc dữ liệu Stack để quản lý quan hệ cha-con (Parent-Child Relationship) dựa trên LEVEL_MAP.
- Logic: Khi một token mới xuất hiện:
 1. Hệ thống kiểm tra Level của token đó.
 2. Thực hiện pop các phần tử trong Stack ra ngoài cho đến khi phần tử ở đỉnh Stack có $Level < Level_hiện_tại$ (tức là tìm thấy cha gần nhất).
 3. Gán token hiện tại làm con của phần tử đỉnh Stack và push token hiện tại vào Stack (nếu nó là Container).
- Hybrid ID Generation Strategy: Để giải quyết vấn đề vòng lặp cây do trùng lặp nội dung, tôi áp dụng chiến lược lại:
 - + Container Nodes (Section, Itemize...): Luôn tạo ID mới (Unique ID) để đảm bảo khung xương cây là tuyến tính và duy nhất.
 - + Leaf Nodes (Sentence, Equation...): Áp dụng Deduplication (gộp trùng) dựa trên nội dung để tối ưu hóa lưu trữ.

2.2 Chuẩn hóa

2.2.1 Data Cleaning (Làm sạch dữ liệu)

Quá trình làm sạch được chia thành hai tầng xử lý riêng biệt phục vụ cho các mục đích khác nhau:

1. General Parsing Cleaning (Phục vụ phần Hierarchical Parsing and Standardization):

- Loại bỏ các lệnh định dạng LaTeX thuần túy như `\centering`, `\hfill`, `\newpage`... vì chúng không mang ý nghĩa ngữ nghĩa.
- Loại bỏ comment (các dòng bắt đầu bằng `%`) để tránh nhiễu thông tin.
- Chuẩn hóa khoảng trắng (Whitespace normalization) để đưa văn bản về dạng dòng đơn.

2. Advanced Preprocessing for Matching (Phục vụ phần Reference Matching Pipeline):

- Được thực hiện bởi class `ReferenceCleaner`.
- LaTeX De-escaping: Sử dụng Regex để quy để "bóc vỏ" các lệnh LaTeX lồng nhau trong Title và Author (Ví dụ: `\textbf{\textit{Title}}` $\rightarrow$ Title).

- Unicode Normalization: Chuyển đổi các ký tự Unicode phức tạp (ví dụ: tên tác giả "Schrödinger") về dạng ASCII chuẩn ("schrodinger") để đảm bảo độ chính xác khi so khớp chuỗi.
- Stop-word Removal: Loại bỏ các hư từ tiếng Anh (the, a, in, on...) trong tiêu đề để tăng trọng số cho các từ khóa chính.

2.2.2 Math Normalization (Chuẩn hóa Toán học)

Các biểu thức toán học trong LaTeX có nhiều cách viết khác nhau. Hệ thống chuẩn hóa chúng về hai định dạng duy nhất:

- Inline Math: Tất cả các dạng $(...)$ hoặc $\begin{math}...\end{math}$ đều được chuyển về dạng $\$... \$$.
- Block Math: Các dạng $\$...\$, \[...\], equation*$ đều được chuyển về môi trường chuẩn $\begin{equation} ... \end{equation}$. Điều này giúp đồng nhất hóa dữ liệu khi trích xuất đặc trưng.

2.2.3 Reference Deduplication (Khử trùng lặp tham chiếu)

Quy trình trích xuất và chuẩn hóa tài liệu tham khảo (refs.bib) sử dụng chiến lược "Active & Lazy Extraction":

- Active Citation Filtering: Hệ thống quét toàn bộ nội dung file .tex để lập danh sách "Active Keys" (các bài báo thực sự được trích dẫn bằng lệnh $\text{\cite}\{...\}$). Chỉ những tài liệu này mới được giữ lại, loại bỏ hàng ngàn entry dư thừa trong file .bib gốc.
- Lazy Extraction (Tối ưu hiệu năng): Với các file .bib kích thước lớn (>2MB), thay vì parse toàn bộ file (tốn kém RAM và thời gian), tôi sử dụng Regex để "quét nhanh" và chỉ trích xuất các block entry tương ứng với Active Keys. Ngược lại đối với file .bib kích thước nhỏ dùng thư viện bibtexparser để parse nội dung file .bib chuẩn xác.
- Deduplication Logic:
 - + Tạo "Fingerprint" cho mỗi reference dựa trên tiêu đề đã được chuẩn hóa (normalize_title_string).
 - + Nếu phát hiện trùng lặp (nhiều entry có cùng Fingerprint), hệ thống sẽ thực hiện Unionization: Gộp thông tin, ưu tiên giữ lại các trường thông tin có độ dài lớn hơn (chi tiết hơn).

2.3 Gán nhãn dữ liệu

Có 2 cách làm chính là gán nhãn thủ công và gán nhãn tự động

1.Gán nhãn thủ công: Nếu một BibTeX entry tìm thấy trong references.json thì sẽ gán arXiv ID của bài báo match. Ngược lại, nhãn được gán giá trị null.

2. Gán nhãn tự động:

* Heuristic Logic: Một cặp (BibTeX Entry, JSON Reference) được coi là khớp nếu thỏa mãn các điều kiện nghiêm ngặt sau:

- Strict Title Matching: Tiêu đề sau khi làm sạch của cả hai phải trùng khớp hoàn toàn.
- Validation Check: Để tránh trùng lặp ngẫu nhiên, cặp dữ liệu phải thỏa mãn thêm ít nhất một trong hai điều kiện:
 - + Năm xuất bản (Year) khớp nhau với sai số cho phép 1 năm (do độ trễ giữa thời gian nộp và xuất bản).
 - + Hoặc tiêu đề có độ dài lớn (>20 ký tự), vì xác suất hai bài báo khác nhau có cùng tiêu đề dài là cực thấp.

* Filtering & Quality Control:

- Loại bỏ các bài báo quá ngắn (có dưới 20 tham chiếu) để tránh nhiễu cục bộ.
- Chỉ chấp nhận các bài báo có tỷ lệ khớp tự động (Auto-match rate) $> 30\%$. Các bài báo có tỷ lệ khớp quá thấp thường ám chỉ lỗi parsing hoặc dữ liệu gốc không đồng bộ, do đó bị loại bỏ khỏi tập huấn luyện.

3. Định dạng

Có cấu trúc sau

```
{
  "PAPER_ID": {
    "BIBTEX_ENTRY_KEY": "TARGET_ARXIV_ID",
    ...
  },
  ...
}
```

Chi tiết:

- PAPER_ID (Key cấp 1): Định danh duy nhất của bài báo gốc (ví dụ: 2201.12345). Đây là khóa chính để liên kết với thư mục dữ liệu.
- BIBTEX_ENTRY_KEY (Key cấp 2): Khóa trích dẫn được trích xuất từ file .tex/.bib (ví dụ: vaswani2017attention). Đây là đại diện cho dữ liệu đầu vào (Input).
- TARGET_ARXIV_ID (Value):

- + Là ID của bài báo đích tìm thấy trong references.json (ví dụ: 1706.03762 hoặc astro-ph/0310723). Đây là nhãn mục tiêu (Target Label) cho lớp Positive Match.
- + Giá trị null: Biểu thị rằng BibTeX Entry này không tương ứng với bất kỳ bài báo nào trong danh sách tham chiếu gốc. Đây là nhãn cho lớp Negative Match (No correspondence).

2.4 Quy trình học máy

2.4.1 Các đặc trưng đã chọn

Để giải quyết bài toán so khớp trích dẫn, tôi mô hình hóa bài toán dưới dạng Phân loại Nhị phân (Binary Classification). Tôi đã xây dựng bộ 7 đặc trưng (features) được chia thành 3 nhóm chính dựa trên các thành phần quan trọng nhất của một trích dẫn khoa học: Tiêu đề, Tác giả và Năm xuất bản.

Biện luận cho việc lựa chọn đặc trưng:

1. Nhóm đặc trưng Tiêu đề (Title Similarity) - Tín hiệu quan trọng nhất:

- Levenshtein Distance Score: Đo lường sự khác biệt về ký tự. Đặc trưng này giúp bắt các lỗi chính tả (typo) hoặc lỗi OCR thường gặp khi trích xuất dữ liệu từ PDF (ví dụ: "Netwrok" vs "Network").
- Jaccard Similarity: Đo lường độ trùng lặp về tập hợp từ vựng. Đặc trưng này giúp xử lý trường hợp các từ trong tiêu đề bị đảo vị trí nhưng vẫn giữ nguyên ngữ nghĩa.
- TF-IDF Cosine Similarity: Đây là đặc trưng nâng cao quan trọng nhất. Khác với Jaccard coi mọi từ như nhau, TF-IDF gán trọng số thấp cho các từ phổ biến (stopwords như "Introduction", "Study of") và trọng số cao cho các từ khóa chuyên ngành hiếm gặp. Điều này giúp mô hình phân biệt được các bài báo có tiêu đề "na ná" nhau nhưng khác về bản chất nội dung.
- Title Length Difference: Là bộ lọc heuristic đơn giản: nếu độ dài hai tiêu đề chênh lệch quá lớn, khả năng trùng khớp là rất thấp.

2. Nhóm đặc trưng Tác giả (Author Similarity):

- Author Overlap Ratio: Tỷ lệ trùng khớp giữa tập hợp tên tác giả.
- First Author Match (Binary): Trong quy chuẩn trích dẫn (như APA, IEEE), tác giả đầu tiên (First Author) là thông tin định danh quan trọng nhất (thường được trích dẫn là *Nguyen et al.*). Do đó, chúng tôi tách riêng việc trùng khớp tác giả đầu tiên thành một đặc trưng nhị phân.

3. Nhóm đặc trưng Thời gian (Year Similarity):

- Year Difference: Khoảng cách tuyệt đối giữa năm trong BibTeX và năm trên Semantic Scholar. Dữ liệu thực tế cho thấy bản ArXiv (preprint) và bản in chính thức thường lệch nhau 0-2 năm. Khoảng cách lớn hơn mức này là dấu hiệu mạnh của việc không trùng khớp.

2.4.2 Mô hình Huấn luyện

Tôi lựa chọn thuật toán Random Forest Classifier cho bài toán này vì các lý do sau:

- Khả năng xử lý dữ liệu hỗn hợp: Random Forest hoạt động tốt với cả đặc trưng liên tục (điểm số tương đồng 0.0 - 1.0) và đặc trưng rời rạc (năm, binary).
- Chống nhiễu (Robustness): Dữ liệu BibTeX đầu vào thường chứa nhiều nhiễu. Cấu trúc ensemble (kết hợp nhiều cây quyết định) của Random Forest giúp giảm thiểu hiện tượng Overfitting so với cây quyết định đơn lẻ.
- Xếp hạng dựa trên xác suất (Probability Ranking): Thay vì chỉ trả về nhãn 0/1, Random Forest cung cấp hàm predict_proba cho phép trích xuất xác suất thuộc lớp "Match". Giá trị này được dùng làm điểm số (score) để xếp hạng (Rank) top 5 ứng viên tiềm năng nhất.

2.4.3 Phân tích Kết quả Đánh giá

Kết quả MRR trên tập test là: 1.0

Đây là một kết quả hoàn hảo tuyệt đối.

2.5 Số liệu thống kê

STT	Nội dung	Kết quả
1	Số lượng bài báo	5000
2	Số lượng bài báo đã parsing thành công	5000
3	Số lượng bài báo không có file tex	4376
4	Số lượng bài báo không có file refs.bib	3358
5	Độ sâu trung bình của phân cấp	2.58
6	Độ sâu tối đa trung bình	3.63
7	Hệ số phân nhánh trung bình	15.95
8	Số lượng trích dẫn trung bình	186
9	Tổng số mẫu huấn luyện	99828

3. Video demo

Link: <https://youtu.be/evJqllevnGE>

TÀI LIỆU THAM KHẢO

1. Semantic Scholar Academic Graph API. <https://api.semanticscholar.org/api-docs/graph>. Accessed: 2025-10-25.
2. arXiv API Basics. <https://info.arxiv.org/help/api/basics.html>. Accessed: 2025-10-25.